

大数据技术课程项目任务书

基于 MovieLens 的分布式增量电影推荐系统

NDCG@10 提升挑战

课程名称	大数据技术
适用对象	博士研究生和硕士研究生
项目形式	建议 3 组队完成并进行个人答辩
推荐数据集	MovieLens 32M
核心评价指标	Top 10 推荐的 NDCG@10

一 项目背景

推荐系统需要同时解决海量行为数据处理、用户兴趣建模、候选召回、结果排序和在线更新等问题。MovieLens 32M 提供匿名用户评分、电影类别、用户标签和时间戳，可在不依赖网络爬虫或外部数据关联的条件下构建完整实验流程。项目要求学生将分布式计算、相似度计算、数据流分析、链接分析、图挖掘和推荐算法组合成一个可运行、可评价、可复现的系统。

二 项目目标

在教师统一的数据划分、候选集和评价程序上，设计并实现分布式增量电影推荐系统，使 Top 10 推荐结果的 NDCG@10 相对热门推荐基线提高不低于 10%。系统还应报告固定运行环境下的数据处理吞吐量、推荐延迟和资源使用情况，但 NDCG@10 作为项目的核心优化指标。

学生应通过基线复现、模型改进和消融实验说明性能提升来自哪些算法或系统设计。实验结果必须能够由教师使用提交的代码和配置文件重新运行。

三 学习目标

- 掌握大规模用户行为数据的清洗、统计、存储和分布式处理方法。
- 理解相似度、近似近邻检索、协同过滤、矩阵分解和排序指标之间的关系。
- 能够把评分时间戳转换为数据流，完成采样、窗口统计和用户画像增量更新。
- 能够把用户与电影建模为二部图，并使用链接分析或随机游走方法改进推荐。
- 形成自主检索资料、复现实验、比较方法和解释结果的研究能力。

四 数据集与实验数据

正式考核使用 MovieLens 32M 稳定基准数据集。数据约含 3200 万条评分、200 万条标签记录、20 万名匿名用户和 8.7 万部电影，压缩包约 239MB。学生从 GroupLens 官方网站下载原始数据，教师提供统一的数据检查、划分和候选集生成脚本。

官方下载地址 [下载MovieLens 32M 数据集](#)

数据文件	主要字段	项目用途
ratings.csv	userId movieId rating timestamp	训练推荐模型并构造时序测试集
movies.csv	movieId title genres	生成电影内容特征和类别画像
tags.csv	userId movieId tag timestamp	构建标签向量和增量兴趣特征
links.csv	movieId imdbId tmdbId	完成编号校验和可选数据扩展

五 数据划分与评价协议

- 正反馈定义** 将评分不低于 4 分的记录作为正反馈，其余记录仅用于兴趣建模或负反馈实验。
- 时间划分** 对每位用户按时间戳排序，前 80%用于训练，中间 10%用于验证，最后 10%用于测试。
- 候选集** 每位测试用户的候选集由测试正样本和 100 个固定负样本组成，统一使用随机种子 20260907。
- 防止泄漏** 训练过程不得读取测试标签；任何时序特征只能使用推荐时刻之前的数据。
- 核心指标** 教师使用统一脚本计算 NDCG@10，并同时记录 Recall@10、吞吐量和单用户推荐延迟。

六 项目任务

任务	模块	主要要求	检查证据
任务一	数据检查与基线	完成数据质量检查、描述性统计和热门推荐基线。	统计报告和基线结果
任务二	相似度与召回	实现精确相似度计算，并使用 LSH 完成近似候选召回。	准确率和效率对比
任务三	分布式推荐	使用 Spark 完成数据处理和至少一种推荐算法的分布式实现。	代码和扩展性实验
任务四	流式增量处理	按时间戳回放评分流，实现采样、窗口统计或画像更新。	流处理演示和日志
任务五	图推荐实验	建立用户与电影二部图，使用链接分析或社区特征改进推荐。	图模型与对比结果
任务六	系统集成	组合召回、特征和排序模块，通过消融实验解释性能变化。	最终模型和消融实验

系统架构最低要求

- 数据层应保留原始数据、清洗数据和训练验证测试划分，所有处理步骤可重复执行。
- 算法层至少包含一个基线模型、一个课程算法模块和一个学生自主学习的改进模块。
- 服务层应输出每位用户的 Top 10 推荐结果，并记录生成时间和模型版本。
- 实验层应统一管理随机种子、参数、日志和指标，支持基线与改进模型的直接比较。

七 项目知识图谱

图中展示了计算机核心课程、大数据课程知识、MovieLens 数据处理、系统实现和评价指标之间的依赖关系。




图 1 项目知识点知识图谱

八 提交成果

- 完整源代码、依赖文件、参数配置和一键运行说明。
- 数据处理与划分脚本，不提交未经许可重新发布的 MovieLens 原始数据。
- 统一格式的 Top 10 推荐结果文件和自动评价结果。
- 项目报告，说明问题定义、算法设计、系统架构、实验设置、结果分析和局限性。
- 小组演示材料、个人贡献说明和答辩记录。

九 基本规范

各组必须记录数据版本、随机种子、软硬件环境和关键参数。引用开源代码、模型或外部资料时应标明来源。教师以统一测试程序和可复现运行结果为准，无法复现或存在数据泄漏的结果不计入核心指标成绩。