MovieLens 32M 分布式增量电影推荐系统 — 结果展示

> 核心指标 **NDCG@10** ｜ 教师协议：每用户 1 正样本 + 100 固定负样本 ｜ 种子 `20260907`
> 数据：32,000,204 评分 ｜ 200,948 用户 ｜ 87,585 电影 ｜ 测试用户 187,278

一、核心结果（30 秒版）

指标	热门基线	最终模型 R13	提升
test NDCG@10	0.754027	**0.872787**	**+15.75%**（要求 ≥ +10%）
Recall@10	0.969003	**0.987126**	+1.81 pt
用户配对 95% CI 下界	—	**+0.117653**	p < 0.001
候选集种子敏感度 σ_seed	—	**0.000363**	5/5 套 lift ≥ 1.1（最小 1.1561）
正样本排到第 1 的比例	53.07%	**73.30%**	+20.2 pt
正样本排出前 10 的比例	3.10%	**1.29%**	−1.81 pt

结论：全部达标判据满足（lift ≥ 1.1、配对 CI 下界 > 0、候选集多种子稳健）。

二、全部实验臂一览

run	方案	test NDCG@10	lift	95% CI 下界
R00_pop	热门基线（训练集热度）	0.754027	1.0000	—
R03_als	Spark MLlib ALS 直接排序	0.279391	0.3705	−0.476235
R06_ltr_f1	LightGBM LambdaRank（10 特征）	0.820496	1.0882	+0.065576
R07_ltr_content	+ 贝叶斯热度 / 加权 genre 画像（12）	0.820212	1.0878	+0.065330
R08_ltr_graph	+ 二部图 PageRank（13）	0.821330	1.0893	+0.066450
R10_ltr_stream	+ 流式 F3 时序比值（16）	0.858661	1.1388	+0.103633
R14_ltr_stream_noes	同 R10 + 固定 300 轮（拆分实验）	0.858790	1.1389	+0.103715
R09_hardneg	R10 + 流行难负样本（负结果）	0.851787	1.1297	+0.096684
R11_ltr_realneg	R10 + 真实负反馈难负样本（负结果）	0.822352	1.0906	+0.067180

run	方案	test NDCG@10	lift	95% CI 下界
R12_ltr_itemcf	+ ItemCF 召回相似度（17，早停失效）	0.829605	1.1002	+0.074477
R13_ltr_itemcf_noes	**同特征 + 固定 300 轮（最终模型）**	**0.872787**	**1.1575**	**+0.117653**

三、增益来源（消融归因）

增量	新增内容	test NDCG 变化
10 → 12	贝叶斯平滑评分、加权 genre 画像	−0.000284（边际为负，信息与既有特征重叠）
12 → 13	二部图 PageRank（任务五）	**+0.001118**
13 → 16	流式 F3 时序比值（任务四）	**+0.037331** ← 最大单项增益
16 → 17 与训练设置（**已拆分**）	① 训练轮数：R10 → R14（早停 213 → 固定 300）	① **+0.000130**（0.9%，等于噪声）
	② **ItemCF 召回特征**：R14 → R13（加 `itemcf_max_sim`）	② **+0.013996**（**99.1%，显著**：95% CI [+0.013355, +0.014598]，p<0.001）

> **拆分实验 R14（2026-10-09）**：补上 2×2 因子设计的空格后，R13 相对 R10 的 +0.014126 可定量分离 —— **增益来自召回特征（99.1%），而非"关闭早停"（0.9%）**。这同时证明早停缺陷只在高并列场景发作（R12），其余早停臂未被污染。

最终模型 R13 的特征重要性 Top-3

排名	特征	组	gain	分裂次数
1	`movie_recent_ratio_7_30`（近期热度比，流式）	F3	8.84e6	1,085
2	`itemcf_max_sim`（ItemCF 召回相似度）	F5	1.95e6	1,622
3	`graph_pagerank`（二部图 PageRank）	F4	1.36e6	496

> 16 个特征 → **17 个**：F1 协同（ALS 分数、热度、活跃度）· F2 内容（genre 画像、年份差）· F3 流式比值 · F4 图 PageRank · F5 召回相似度。

四、系统与工程指标

维度	实测
数据处理吞吐	Spark 分布式统计 32.7 s；流式窗口聚合 2889 万事件 69.6 s（加入采样与增量画像后 210.1 s）

维度	实测
推荐延迟	**0.250 ms/用户**（纯推理，403,403 行/s）；管线代理 3.33 ms/用户
Spark 扩展性	ALS 训练吞吐 local[2] 95,897 → local[8] **188,841 ratings/s（加速比 1.97）**
资源占用	峰值内存 **9.27 GB**（16 GB 机器）；全流程产物约 2.5 GB
分布式一致性	Spark 侧统计与单机 pandas **逐项一致（一致率 1.000000）**
流式处理	24 个有序回放文件 / 12 个 micro-batch / 采样 288,229 行 / 增量画像 2,173,471 个 (用户,题材) 对
Top-10 提交	1,872,780 行 = 187,278 用户 × 10，格式与评测脚本 tie-break 完全一致
单元测试	13 项通过（划分时序、候选集形状/分布、NDCG、bootstrap、召回特征、画像衰减）

五、六个任务交付一览

任务	交付	关键证据
一 数据检查与基线	质量校验 + 描述性统计 + 热门基线	`outputs/reports/data_quality.md`、`dataset_stats.md`、`docs/data_card.md`（4 文件 MD5 全部与官方一致）、R00 = 0.7540
二 相似度与召回	精确 ItemCF + SimHash LSH 9 组参数	`outputs/reports/recall_lsh.md`：精确构建 11.0 s / 单查询 1.17 ms；LSH 高召回需扫 67–99% 物品 → 本规模无净收益
三 分布式推荐	**Spark MLlib ALS**（训练 + 候选打分均分布式）	`scalability.md`（加速比 1.97）、`spark_features.md`（一致率 1.000000）、`resources.md`
四 流式增量处理	时间戳回放 + 窗口统计 + **采样** + **增量画像**	`stream_demo.md`（24 文件有序性 / 12 微批 / 时序安全验算）、`stream_profile_demo.md`（EWMA 画像随批次演化）
五 图推荐实验	用户-电影二部图 PageRank（+ 两项负结果）	20,000 物品 / 100 万边 / 覆盖 99.61% 正反馈；PageRank +0.0011；walk 与社区特征经消融关闭
六 系统集成	召回 + 特征 + 排序组合，消融解释	17 特征 LambdaRank；`docs/消融总表.md`（10 臂 + 归因 + 负结果）

六、复现方式

```
# 1. 获取代码
git clone https://github.com/Jake4455/movielens-recsys.git    # 私有仓库，需授权
# 2. 下载 MovieLens 32M 并解压到 data/ml-32m/（原始数据未随仓库提交）
# 3. 安装依赖
conda create -n mlrecsys python=3.11 -y && conda activate mlrecsys && pip install -r
requirements.txt
# 4. 复现最终模型（17 特征 + 固定 300 轮）
python run_all.py --config conf/itemcf_noes.yaml --stages stream,ltr --force
# 5. 评测与测试
python -m pytest tests -q
```

七、可信度说明与已知边界

1. **口径修复**：候选集负采样曾因 `np.unique` 截断而偏离"均匀随机"文档口径（约 51% 目录不可达），2026-10-08 修复后**全臂重跑**；修复前 lift 曾虚高为 +23.56%，现为真实的 +15.75%。
2. **早停缺陷**：LightGBM 内部验证指标按行序打破并列，而训练组把正样本置于每组首行；同一组特征开早停仅 0.8296、关闭早停得 0.8728。最终模型因此采用固定 300 轮。**影响面已实测（R14）**：该缺陷只在高并列场景（含 96% 零值的 ItemCF 特征）发作，其余早停臂未被拖累。
3. ~~归因待补~~ ✅ **已闭环（2026-10-09，R14 拆分实验）**：R13 的 +0.014126 中，**召回特征贡献 +0.013996（99.1%，统计显著）**、训练轮数贡献 +0.000130（噪声）。此前基于 R12 的"增益主要来自关早停"推测**已被证伪**。
4. **协议口径**：教师端候选集生成规则与评测脚本相关性定义（Q1/Q6/Q7）尚未确认；本地按"全库均匀随机 + 排除用户已交互项"复现。
5. **分布式程度**：Spark 运行于单机 `local[8]`（伪分布式），扩展性结论不代表真实集群。
6. **诚实记录**：如实记录 5 类负结果（两种难负样本、绝对时间口径、随机游走/社区特征、LSH 无净收益、移植特征边际为负）与早停陷阱的定位过程，全部可复核。

指标源文件： `outputs/leaderboard.csv`、`outputs/metrics/*.json`、`outputs/reports/seed_robustness_R13_ltr_itemcf_noes.md`*；详细消融见* `docs/消融总表.md`*，完整报告见* `docs/项目报告.md`。