

Contents

MovieLens 32M 分布式增量电影推荐系统—结果展示1

一、核心结果 (30 秒版)

二、全部实验臂一览

三、增益来源 (消融归因)

四、系统与工程指标

五、六个任务交付一览

六、复现方式

七、可信度说明与已知边界

1

1

2

2

3

3

4

MovieLens 32M 分布式增量电影推荐系统—结果展示

核心指标 **NDCG@10** | 教师协议: 每用户 1 正样本 + 100 固定负样本 | 种子 20260907 数据: 32,000,204 评分 | 200,948 用户 | 87,585 电影 | 测试用户 187,278

一、核心结果 (30 秒版)

指标	热门基线	最终模型 R13	提升
test NDCG@10	0.754027	0.872787	+15.75% (要求 $\geq +10\%$)
Recall@10	0.969003	0.987126	+1.81 pt
用户配对 95% CI 下界	—	+0.117653	$p < 0.001$
候选集种子敏感度 σ_{seed}	—	0.000363	5/5 套 lift ≥ 1.1 (最小 1.1561)
正样本排到第 1 的比例	53.07%	73.30%	+20.2 pt
正样本排出前 10 的比例	3.10%	1.29%	-1.81 pt

结论：全部达标判据满足 (lift ≥ 1.1 、配对 CI 下界 > 0 、候选集多种子稳健)。

二、全部实验臂一览

run	方案	test NDCG@10	lift	95% CI 下界
R00_pop	热门基线 (训练集热度)	0.754027	1.0000	—
R03_als	Spark MLlib ALS 直接排序	0.279391	0.3705	-0.476235
R06_ltr_f1	LightGBM LambdaRank (10 特征)	0.820496	1.0882	+0.065576
R07_ltr_content	+ 贝叶斯热度 / 加权 genre 画像 (12)	0.820212	1.0878	+0.065330
R08_ltr_graph	+ 二部图 PageRank (13)	0.821330	1.0893	+0.066450
R10_ltr_stream	+ 流式 F3 时序比值 (16)	0.858661	1.1388	+0.103633
R14_ltr_stream_noes	同 R10 + 固定 300 轮 (拆分实验)	0.858790	1.1389	+0.103715
R09_hardneg	R10 + 流行难负样本 (负结果)	0.851787	1.1297	+0.096684

run	方案	test NDCG@10	lift	95% CI 下界
R11_ltr_realneg	R10 + 真实负反馈难负样本 (负结果)	0.822352	1.0906	+0.067180
R12_ltr_itemcf	+ ItemCF 召回相似度 (17, 早停失效)	0.829605	1.1002	+0.074477
R13_ltr_itemcf_noes	同特征 + 固定 300 轮 (最终模型)	0.872787	1.1575	+0.117653

三、增益来源 (消融归因)

增量	新增内容	test NDCG 变化
10 → 12	贝叶斯平滑评分、加权 genre 画像	-0.000284 (边际为负, 信息与既有特征重叠)
12 → 13	二部图 PageRank (任务五)	+0.001118
13 → 16	流式 F3 时序比值 (任务四)	+0.037331 ← 最大单项增益
16 → 17 与训练设置 (已拆分)	① 训练轮数: R10 → R14 (早停 213 → 固定 300) ② ItemCF 召回特征 : R14 → R13 (加 itemcf_max_sim)	① +0.000130 (0.9%, 等于噪声) ② +0.013996 (99.1%, 显著) : 95% CI [+0.013355, +0.014598], p<0.001)

拆分实验 R14 (2026-10-09): 补上 2×2 因子设计的空格后, R13 相对 R10 的 +0.014126 可定量分离——**增益来自召回特征 (99.1%), 而非“关闭早停” (0.9%)**。这同时证明早停缺陷只在高并列场景发作 (R12), 其余早停臂未被污染。

最终模型 R13 的特征重要性 Top-3

排名	特征	组	gain	分裂次数
1	movie_recent_ratio37_30 (近期热度比, 流式)	F3	8.84e6	1,085
2	itemcf_max_sim (ItemCF 召回相似度)	F5	1.95e6	1,622
3	graph_pagerank (二部图 PageRank)	F4	1.36e6	496

16 个特征 → **17 个**: F1 协同 (ALS 分数、热度、活跃度) · F2 内容 (genre 画像、年份差) · F3 流式比值 · F4 图 PageRank · F5 召回相似度。

四、系统与工程指标

维度	实测
数据处理吞吐	Spark 分布式统计 32.7 s; 流式窗口聚合 2889 万事件 69.6 s (加入采样与增量画像后 210.1 s)
推荐延迟	0.250 ms/用户 (纯推理, 403,403 行/s); 管线代理 3.33 ms/用户
Spark 扩展性	ALS 训练吞吐 local[2] 95,897 → local[8] 188,841 ratings/s (加速比 1.97)

维度	实测
资源占用 分布式一致性	峰值内存 9.27 GB (16 GB 机器); 全流程产物约 2.5 GB Spark 侧统计与单机 pandas 逐项一致 (一致率 1.000000)
流式处理	24 个有序回放文件 / 12 个 micro-batch / 采样 288,229 行 / 增量画像 2,173,471 个 (用户, 题材) 对
Top-10 提交	1,872,780 行 = 187,278 用户 × 10, 格式与评测脚本 tie-break 完全一致
单元测试	13 项通过 (划分时序、候选集形状/分布、NDCG、bootstrap、召回特征、画像衰减)

五、六个任务交付一览

任务	交付	关键证据
一 数据检查与基线	质量校验 + 描述性统计 + 热门基线	outputs/reports/data_quality.md、dataset_stats.md、docs/data_card.md (4 文件 MD5 全部与官方一致)、R00 = 0.7540
二 相似度与召回	精确 ItemCF + SimHash LSH 9 组参数	outputs/reports/recall_lsh.md: 精确构建 11.0 s / 单查询 1.17 ms; LSH 高召回需扫 67-99% 物品 → 本规模无净收益
三 分布式推荐	Spark MLlib ALS (训练 + 候选打分均分布式)	scalability.md (加速比 1.97)、spark_features.md (一致率 1.000000)、resources.md
四 流式增量处理	时间戳回放 + 窗口统计 + 采样 + 增量画像	stream_demo.md (24 文件有序性 / 12 微批 / 时序安全验算)、stream_profile_demo.md (EWMA 画像随批次演化)
五 图推荐实验	用户-电影二部图 PageRank (+ 两项负结果)	20,000 物品 / 100 万边 / 覆盖 99.61% 正反馈; PageRank +0.0011; walk 与社区特征经消融关闭
六 系统集成	召回 + 特征 + 排序组合, 消融解释	17 特征 LambdaRank; docs/消融总表.md (10 臂 + 归因 + 负结果)

六、复现方式

```
# 1. 获取代码
git clone https://github.com/Jake4455/movielens-recsys.git # 私有仓库, 需授权
# 2. 下载 MovieLens 32M 并解压到 data/ml-32m/ (原始数据未随仓库提交)
# 3. 安装依赖
conda create -n mlrecsys python=3.11 -y && conda activate mlrecsys && pip install -r requirements.txt
# 4. 复现最终模型 (17 特征 + 固定 300 轮)
python run_all.py --config conf/itemcf_noes.yaml --stages stream,ltr --force
# 5. 评测与测试
python -m pytest tests -q
```

七、可信度说明与已知边界

1. **口径修复**: 候选集负采样曾因 np.unique 截断而偏离“均匀随机”文档口径 (约 51% 目录不可达), 2026-10-08 修复后**全臂重跑**; 修复前 lift 曾虚高为 +23.56%, 现为真实的 +15.75%。
2. **早停缺陷**: LightGBM 内部验证指标按行序打破并列, 而训练组把正样本置于每组首行; 同一组特征开早停仅 0.8296、关闭早停得 0.8728。最终模型因此采用固定 300 轮。**影响面已实测 (R14)**: 该缺陷只在高并列场景 (含 96% 零值的 ItemCF 特征) 发作, 其余早停臂未被拖累。
3. 归因待补 ✓ **已闭环 (2026-10-09, R14 拆分实验)**: R13 的 +0.014126 中, **召回特征贡献 +0.013996 (99.1%, 统计显著)**、训练轮数贡献 +0.000130 (噪声)。此前基于 R12 的“增益主要来自关早停”推测**已被证伪**。
4. **协议口径**: 教师端候选集生成规则与评测脚本相关性定义 (Q1/Q6/Q7) 尚未确认; 本地按“全库均匀随机 + 排除用户已交互项”复现。
5. **分布式程度**: Spark 运行于单机 local[8] (伪分布式), 扩展性结论不代表真实集群。
6. **诚实记录**: 如实记录 5 类负结果 (两种难负样本、绝对时间口径、随机游走/社区特征、LSH 无净收益、移植特征边际为负) 与早停陷阱的定位过程, 全部可复核。

指标源文件: `outputs/leaderboard.csv`, `outputs/metrics/*.json`, `outputs/reports/seed_robustness_R13_Lt`
详细消融见 `docs/消融总表.md`, 完整报告见 `docs/项目报告.md`。